



Tema 5:

Redes Neuronales Artificiales

Departamento de Tecnologías de la Información

Área de Ciencias de la Computación e Inteligencia Artificial



Grado en Ingeniería en Informática. Inteligencia Artificial Aplicada a Robots

1

Tema 5: Redes Neuronales Artificiales

Redes Neuronales Artificiales

Redes Neuronales Artificiales: Neurocomputación

- Tema 5: Redes Neuronales Artificiales.
- Tema 6: Deep Learning.



Grado en Ingeniería en Informática. Inteligencia Artificial Aplicada a Robots

2

2

Tema 5: Redes Neuronales Artificiales

Índice:

1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

Tema 5: Redes Neuronales Artificiales

Índice:

1. **Introducción**
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

1. Introducción

• El cerebro humano


- Órgano biológico de una extraordinaria complejidad
- Situado en el encéfalo, en la proximidad de la mayoría y los principales sentidos
- Formado por una red de neuronas interconectadas
- Sobre 100 mil millones de neuronas: 15 mil mill. en la corteza y 85 mil mill. en el encéfalo
- Unas 10 mil conexiones por neurona
- La conexión es a través de los axones: unas fibras largas de protoplasma (elemento químico formado por agua (sobretudo), sales, proteínas, enzimas, glúcidos y lípidos) (medirían puestas en fila, unos 160 mil kms), que conducen impulsos eléctricos
- Computadora biológica, distinta en sus principios a la electrónica, pero similar en cuanto a que: adquiere datos del exterior, los almacena y los procesa.



5

• El cerebro humano

- Velocidad:
 - Sus impulsos eléctricos se transmiten a 350 km/h
 - 10 mil billones de cálculos por segundo (lejos aún del rendimiento de las computadoras electrónicas)
- Tiene 10 billones de conexiones entre neuronas
- Consume el 20% del oxígeno del cuerpo humano, y una cantidad de energía equivalente a 25W
- Tiempo de conmutación: 1 milésima
- Tiempo en reconocer una imagen: 1 décima
- Para resolver el problema de reconocimiento de imágenes, emplea bastante más de 100 pasos de procesamiento...
- El cerebro humano presenta paralelismo masivo sobre una representación distribuida



6

- El cerebro humano (y II)
 - No está programado genéticamente para tareas como, por ejemplo, reconocer caras, sino que es una habilidad que entrena desde el nacimiento, y se estima que tarda unos 200 días para conseguirlo (lo hace el lóbulo temporal (bajo la sien) en una zona del tamaño de un guisante)
 - Este entrenamiento temprano en esta labor, es la que hace que el cerebro “vea” caras en objetos (*pareidolia facial*) (por ejemplo, en nubes, o en manchas...etc.).
 - Cada neurona se activa con determinado rasgo facial (ejemplos: nariz ancha, ojos pequeños, ...etc.) (hay grupos de ellas para cada rasgo), los cuales se combinan en firmas para crear la imagen de la cara completa (hasta hace poco, se pensaba que cada neurona retenía o codificaba una cara o persona concreta)
 - Igual ocurre con el resto de habilidades de reconocimiento (objetos, etc.): se entrenan
 - Los estudios dicen que son grupos de pocas neuronas las que realmente se utilizan para esta labor de reconocimiento de caras.

- Excepto en tareas muy específicas (ej: en el cálculo aritmético), el cerebro humano es superior a cualquier computador actual:
 - Procesamiento de imágenes, voz, datos inexactos o con ruido, lenguaje natural, (en general en tareas de percepción no simples)
 - Predicción,
 - Control...
- Características interesantes, en resumen, del cerebro humano:
 - Robusto: Su funcionamiento no se altera ante fallos poco importantes.
 - Flexible: Se adapta con facilidad a un entorno cambiante.
 - Puede tratar con información ambigua o incompleta.
 - Pequeño, compacto y consume relativamente poca energía.

*Pero algo está
cambiando
actualmente ...*

- **Objetivos de la Neurocomputación:**
 - En primer lugar, comprender los **principios** empleados que explican las **capacidades** de los seres dotados de inteligencia:
 - Interpretación de percepciones sensoriales.
 - Clasificación por categorías.
 - Capacidad de abstracción.
 - Extracción de características.
 - Memoria asociativa, etc.
 - En segundo lugar, **desarrollar modelos computacionales** que exhiban algunas de estas capacidades e implementarlos.

Tema 5: Redes Neuronales Artificiales

Índice:

1. Introducción
2. **Concepto básico de red neuronal**
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

2. Concepto básico de red neuronal

- *Def:*
Sistema de cómputo artificial inspirado en sistemas nerviosos biológicos.
- Características esenciales de los *sistemas nerviosos biológicos*:
 - Combinan una gran cantidad de elementos simples de procesamiento altamente interconectados
 - Las propiedades computacionales dependen de las interconexiones
 - El conexionado cambia con la experiencia y el aprendizaje
 - Su capacidad de cómputo se desarrolla mediante un proceso adaptativo de aprendizaje
 - Realizan un procesamiento masivamente paralelo
 - Son sistemas no lineales porque una neurona es básicamente un dispositivo no lineal

Tema 5: Redes Neuronales Artificiales


Índice:

1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

3. Computación Neuronal frente a Convencional

Computación Convencional:

- Basados en la **arquitectura John von Neumann**, la cual, utiliza:
 - Un microprocesador relativamente complejo.
 - Una memoria que almacena la información en localizaciones específicas.
- Su **operación es secuencial, centralizada y síncrona**
 - 1. Carga una instrucción de la memoria
 - 2. Carga los datos de la memoria
 - 3. Ejecuta la instrucción
 - 4. Almacena los resultados en la memoria
 - 5. Vuelve al paso 1
- Aplican **razonamiento deductivo**: ejecutan una serie de pasos conocidos y preestablecidos en el programa para resolver el problema.
- El hardware **no es tolerante a fallos** y la conectividad de elementos es fija
- Los eventos suceden en el rango de nseg. (10^{-9} seg.)



Computación Neuronal:

- Basados en los sistemas biológicos neuronales
 - Se utilizan muchos **procesadores “virtuales” sencillos**.
 - La **información se almacena en las interconexiones**: es distribuida y redundante.
- Su **operación es paralela, conectiva y asíncrona**. **Se fundamenta en el aprendizaje de problemas, y no en su algoritmo.**
- Aplican **razonamiento inductivo**: dados una serie de patrones de entrenamiento, aprenden los pasos a ejecutar.
- Son **tolerantes a fallos** porque la **información está distribuida**, las operaciones son colectivas, y la **conectividad de los elementos se adapta al problema**; cada elemento individual puede fallar y el sistema sólo se degrada, pero no deja de funcionar.
- En un sistema nervioso biológico, los eventos suceden en el rango de mseg. (10^{-3} seg.) y sin embargo globalmente, *tradicionalmente* se resuelven **ciertos problemas** a mayor velocidad de la que consigue un ordenador convencional (aquí también las cosas están cambiando).


Tema 5: Redes Neuronales Artificiales

Índice:


1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. **Ventajas de un sistema de cómputo neuronal**
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

4. Ventajas de un sistema de cómputo neuronal

- **Capacidad de aprender:** Generalmente, se necesita una colección de ejemplos representativos; ej: en una tarea de clasificación:



- **Es capaz de generalizar** (responder ante entradas que no ha visto nunca)



- **Capacidad de adaptación a los cambios** sobrevenidos que puedan afectar a la tarea que está resolviendo:
 - Útil, por ejemplo, para tareas de control adaptativo,
 - y/o tareas de procesamiento de señal adaptativo
- **Tolerancia a fallos:**
 - La destrucción parcial de una red conduce a una degradación de su comportamiento, pero mantiene en general sus capacidades

Tema 5: Redes Neuronales Artificiales


Índice:

1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. Campos de aplicación
8. Bibliografía

5. Neurocomputación: De la neurona biológica a la artificial

- 5.1. Las neuronas biológicas
- 5.2. Las neuronas artificiales
- 5.3. Tipos clásicos de funciones de transferencia
- 5.4. Ejemplo de funcionamiento de una neurona
- 5.5. Arquitecturas de redes neuronales

5.1 Las neuronas biológicas:



19

19

- Las neuronas bio trabajan con una composición de dos tipos de señales:
 - eléctricas: que se generan en el cuerpo celular y se transmiten por el axón
 - químicas: que se transmite entre los terminales axónicos (salidas) de una neurona, y las dendritas (entradas) de otra
- Esos contactos electroquímicos son implementados por unas moléculas de neurotransmisores a través de unos contactos llamados **sinapsis**.
- Las **sinapsis** pueden ser de dos tipos:
 - excitadoras: facilitan la generación de impulsos eléctricos
 - inhibidoras: dificultan esa generación
- Observaciones de Hebb: el **conexionado** cambia con la experiencia, i.e.: Hay uniones sinápticas que se refuerzan y otras que se debilitan, por tanto, hay cambios fisiológicos en este proceso.

20

20


- **Funcionamiento:**
 - El efecto en la neurona receptora es la **elevación o disminución** de un potencial eléctrico dentro del soma o cuerpo celular. **Cuando este potencial alcanza un cierto umbral, la célula emite a su vez un pulso de intensidad y duración determinadas.**
- Cada neurona biológica está conectada a entre 1.000 y 10.000 neuronas
 - El grado de conectividad del cerebro es muchísimo mayor que el del más grande de los supercomputadores actuales.

5.2. Neuronas artificiales:

- Las **señales** que llegan a las dendritas se representan como x_1, x_2, \dots, x_n
- Las **conexiones** sinápticas se representan por unos **pesos** w_{j1}, w_{j2}, w_{jn} que ponderan (multiplican) a las entradas.


Si el peso entre las neuronas j e i es:

- a) positivo, representa una sinapsis excitadora
- b) negativo, representa una sinapsis inhibidora
- c) cero, no hay conexión



- La acción integradora (Net_j) del cuerpo celular (o actividad interna de cada célula) se presenta por un sumador:

$$Net_j = w_{j1} \cdot x_1 + w_{j2} \cdot x_2 + \dots + w_{jn} \cdot x_n = \sum_{i=1}^n w_{ji} \cdot x_i$$



23

23

- La salida de la neurona se representa por y_j .
- Dicha salida se obtiene mediante una función que, en general, se denomina **función de salida**, de **transferencia** o de **activación**. Esta función depende de:
 - El valor de Net_j (ó actividad integradora)
 - y del valor de un parámetro θ_j , el cual representa el **umbral de activación** de la neurona

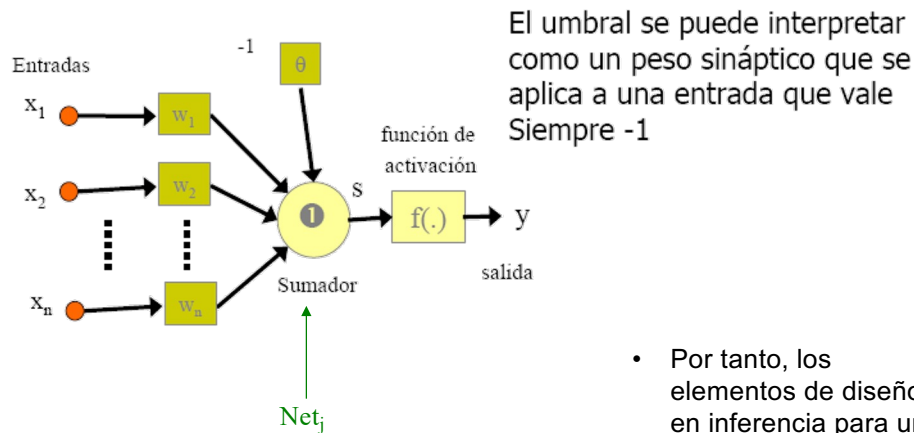
$$y_j = f(Net_j - \theta_j) = f\left(\sum w_{ji} \cdot x_i - \theta_j\right)$$

The diagram is identical to the one on slide 23, showing a green square box labeled Net_j with inputs x_1, x_2, \dots, x_n and weights $w_{j1}, w_{j2}, \dots, w_{jn}$, and an output y_j . Arrows from the text above point to the summation term in the equation and the threshold θ_j .

24

24

- Podríamos representarlo también así:



- Por tanto, los elementos de diseño en inferencia para una neurona son: f y θ

25

5.3. Tipos clásicos de funciones de transferencia (f), activación o salida

- Función de escalón** (o **Haviside**). Representa una neurona con sólo dos estados de activación: activada (1), e inhibida (0 ó -1)


$$y_j = H(Net_j - \theta_j) = \begin{cases} 1, & \text{si } Net_j \geq \theta_j \\ -1, & \text{si } Net_j < \theta_j \end{cases}$$

- Función lineal:**

$$y_j = Net_j - \theta_j$$

- Función ReLU** (unidad lineal modificada)

$$y_j = \max(0, Net_j - \theta_j)$$




26

- Función lineal a tramos:**

$$y_j = \begin{cases} 1, & \text{si } Net_j \geq \theta_j + a \\ Net_j - \theta_j, & \text{si } |Net_j - \theta_j| < a \\ -1, & \text{si } Net_j < \theta_j - a \end{cases}$$


- Función sigmoideal (o sigmoidea):**



$$y_j = \frac{1}{1 + e^{-\lambda(Net_j - \theta_j)}}$$

Tanh (Tangente hiperbólica)

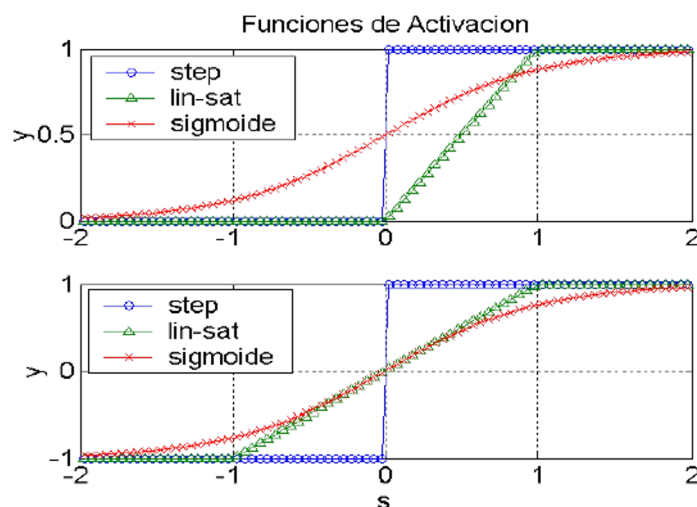
$$y_j = \frac{2}{1 + e^{-\lambda(Net_j - \theta_j)}} - 1$$



- Función radial:**

$$y_j = e^{-\left(\frac{Net_j - \theta_j}{\sigma}\right)^2}$$

27




28

5.4. Ejemplo de funcionamiento de una neurona

- Cada neurona en la red es un elemento básico de procesamiento.
- El modelo simplificado de neurona biológica permite
 - representación entrada-salida
 - múltiples entradas, salida única
 - diferente influencia de entradas en salida mediante “pesos” (w_i).
- w_i : parámetros de la neurona
- Relación entrada-salida no-lineal
- Diferentes opciones para la función de transferencia $f(.)$
 - step, sat, sigm, tanh, ...
- Capacidad de adaptación
 - variación de sus “pesos” con algún objetivo

29

- Ejemplo simple de una función para aprender, con dos entradas y una salida, con una neurona, para implementar la función OR:



x_1	x_2	Y
0	0	0
0	1	1
1	0	1
1	1	1

30

Parámetros y Configuración para Inferencia:

- Función de transferencia (f): Función escalón
- Umbral (θ): 0.5

Parámetros y Configuración para Aprendizaje:

- El objetivo es encontrar los valores de w_1 y w_2 , tal que la salida sea la correcta (es decir: cuando se entrena una RNA, establecemos un mecanismo para que se ajusten sus pesos)
- Mecanismo iterativo de refinamiento/ajuste del valor de los pesos
 - Inicialmente los pesos tienen un valor establecido
 - Los pesos se actualizan iterativamente con esta ecuación

$$w_i = w_i + a D x_i, \quad i = 1,2 \text{ (si es el caso de tener dos entradas)}$$

donde a = parámetro de entrenamiento y D es la diferencia calculada entre la salida deseada y la salida real de la neurona

31

	Entradas		Salida deseada	Pesos iniciales		Salida actual	Diferencia	Pesos finales	
Iteración	x_1	x_2	Z	w_1	w_2	Y	D	w_1	w_2
1	0	0	0	0.1	0.3	0	0	0.1	0.3
	0	1	1	0.1	0.3	0	1	0.1	0.5
	1	0	1	0.1	0.5	0	1	0.3	0.5
	1	1	1	0.3	0.5	1	0	0.3	0.5

$a=0.2$, $\theta=0.5$, $D=Z-Y$, $Y = w_1 x_1 + w_2 x_2$, $w_i \text{ (final)} = w_i \text{ (inicial)} + a * D * x_i$, (con $i = 1,2$)

En color rojo: valores fijados a mano de inicio (valores semilla de los pesos)

En color azul: valores resultado del cálculo de la fórmula

En negro: valores copia y pega (lado izquierdo de la tabla) y cálculos (lado derecho de la tabla)

32

	Entradas		Salida deseada	Pesos iniciales		Salida actual	Diferencia	Pesos finales	
Iteración	x ₁	x ₂	Z	w ₁	w ₂	Y	D	w ₁	w ₂
1	0	0	0	0.1	0.3	0	0	0.1	0.3
	0	1	1	0.1	0.3	0	1	0.1	0.5
	1	0	1	0.1	0.5	0	1	0.3	0.5
	1	1	1	0.3	0.5	1	0	0.3	0.5
2	0	0	0	0.3	0.5	0	0	0.3	0.5
	0	1	1	0.3	0.5	0	1	0.3	0.7
	1	0	1	0.3	0.7	0	1	0.5	0.7
	1	1	1	0.5	0.7	1	0	0.5	0.7
3	0	0	0	0.5	0.7	0	0	0.5	0.7
	0	1	1	0.5	0.7	1	0	0.5	0.7
	1	0	1	0.5	0.7	0	1	0.7	0.7
	1	1	1	0.7	0.7	1	0	0.7	0.7
4	0	0	0	0.7	0.7	0	0	0.7	0.7
	0	1	1	0.7	0.7	1	0	0.7	0.7
	1	0	1	0.7	0.7	1	0	0.7	0.7
	1	1	1	0.7	0.7	1	0	0.7	0.7

- En el ejemplo se observa que la ecuación aprendida que calcula el OR sería:

$$y = 0.7 x_1 + 0.7 x_2$$

- Esta técnica se puede aplicar para resolver un numero extremadamente grande de problemas, en lo que constituye un modelo básico de aprendizaje automático: se le presentan ejemplos (experiencia), y el mecanismo aprende un modelo (forma de generalizarlos)
- Pero...*

- ¿Podríamos calcular los valores de w_1 y w_2 si quisiéramos conseguir una función NAND?

x_1	x_2	Y
0	0	1
0	1	1
1	0	1
1	1	0

- Obsérvese que para ello, deberíamos poder obtener una salida de valor 1 en la ecuación $Y = w_1 x_1 + w_2 x_2$ cuando x_1 y x_2 son 0 (imposible!!)
- Para que eso pudiese ser posible, hay que emplear un término de sesgo, con valor 1, esto es una entrada adicional fija $x_0 = 1$

35

- La tabla ahora sería:

Iteración	Entradas			Salida deseada	Pesos iniciales			Salida actual	Diferencia	Pesos finales		
	x_0	x_1	x_2	Z	w_0	w_1	w_2	Y	D	w_0	w_1	w_2
1	1	0	0	1	0.9	0.1	0.1	1	0	0.9	0.1	0.1
	1	0	1	1	0.9	0.1	0.1	1	0	0.9	0.1	0.1
	1	1	0	1	0.9	0.1	0.1	1	0	0.9	0.1	0.1
	1	1	1	0	0.9	0.1	0.1	1	-1	0.8	0	0
2	1	0	0	1	0.8	0	0	1	0	0.8	0	0
	1	0	1	1	0.8	0	0	1	0	0.8	0	0
	1	1	0	1	0.8	0	0	1	0	0.8	0	0
	1	1	1	0	0.8	0	0	1	-1	0.7	-0.1	-0.1
3	1	0	0	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	0	1	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	1	0	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	1	1	0	0.7	-0.1	-0.1	0	0	0.7	-0.1	-0.1
4	1	0	0	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	0	1	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	1	0	1	0.7	-0.1	-0.1	1	0	0.7	-0.1	-0.1
	1	1	1	0	0.7	-0.1	-0.1	0	0	0.7	-0.1	-0.1

$$a=0.1, \theta=0.5, D=Z-Y, Y=w_0 x_0 + w_1 x_1 + w_2 x_2, (\text{con } x_0=1), w_i(\text{final}) = w_i(\text{inicial}) + a * D * x_i, (\text{con } i=0,1,2)$$

36


5.5. Arquitecturas de redes neuronales

- La arquitectura de una red es la manera en que se disponen sus neuronas.
- La **función** que desarrolla **cada neurona** en la red es un **elemento básico de procesamiento**: **pero su arquitectura de interconexión es vital**.
- La **cooperación** de las **neuronas** es la que produce los efectos deseados.
- Las **neuronas**, según su **situación en la red** pueden ser:
 - De entrada: reciben las señales de entrada. Todas las neuronas de entrada se dice que forman la capa de entrada.
 - De salida: envían las señales de salida al exterior.
 - Ocultas: no tienen ningún contacto con el exterior. Forman la capa o capas ocultas.

37

Grado en Ingeniería en Informática. Inteligencia Artificial Aplicada a Robots

37



38

Grado en Ingeniería en Informática. Inteligencia Artificial Aplicada a Robots

38

- Las neuronas pueden interactuar (conectarse) entre sí de tres formas:
 - Interacción hacia delante (*feed-forward*):
Interacción entre neuronas de entrada y capa siguiente, o entre capa oculta y la siguiente capa (otra oculta o de salida).
 - Interacción lateral: Interacción o conexión entre neuronas de la misma capa.
 - Interacción hacia atrás (*realimentación* o *feed-back*):
Interacción entre neuronas de capas más cercanas a la salida con las más cercanas a la entrada.

- **Consideraciones:**
 - El tamaño de una RNA está directamente relacionado con las capacidades de la red.
 - El tamaño depende del número de capas y del número de neuronas ocultas por capa.
 - Por tanto, las capacidades de una red dependen del número de neuronas ocultas.
 - El Perceptrón Multicapa (una RNA con una capa de entrada, una de salida, y al menos una oculta), con suficientes neuronas no lineales, puede aproximar cualquier tipo de función o relación continua entre un grupo de variables de entrada y de salida.

Tema 5: Redes Neuronales Artificiales

Índice:

1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
- 6. Tipos de aprendizaje**
7. Campos de aplicación
8. Bibliografía

6. Tipos de aprendizaje

- Recordemos la diferencia sustancial entre los modos de desarrollo de una red neuronal y una aplicación de software:

La red *no se programa* sino que *se entrena*

- En un ordenador, el procesamiento de datos se basa en la ejecución de un programa que es una lista ordenada de instrucciones que realiza un cierto algoritmo.
- Las redes neuronales son pues la solución para problemas complejos difícilmente programables.
 - Multitud de elementos simples interconectados.
 - Procesamiento no lineal.

- El **aprendizaje o entrenamiento** de una red neuronal puede ser:
 - **General**: se **aprende la topología** de la red (capas y número de neuronas por capa) a la vez que el **tipo de neuronas** constituyentes y su **interconexión**.
 - **Paramétrico**: se **parte de una topología y de un tipo de neuronas** y se **aprenden los parámetros** relacionados con la operación de las neuronas (por ejemplo, los **umbrales de activación**) y los **pesos sinápticos**. Este aprendizaje es más sencillo y **ha sido el habitual durante muchos años en RNAs convencionales**.

Tema 5: Redes Neuronales Artificiales

Índice:

1. Introducción
2. Concepto básico de red neuronal
3. Computación neuronal frente a convencional
4. Ventajas de un sistema de cómputo neuronal
5. Neurocomputación: De la neurona biológica a la artificial
6. Tipos de aprendizaje
7. **Campos de aplicación**
8. Bibliografía

7. Campos de aplicación

- **Reconocimiento de patrones:**
 - El sistema neuronal almacena un conjunto de patrones. Cuando se le presenta un patrón distorsionado o con ruido, debe proporcionar el patrón original
 - Reconocimiento de *speakers* en telecomunicaciones
 - Reconocimiento facial
 - Reconocimiento de caracteres manuscritos
 - Reconocimiento de objetos tridimensionales, etc.
- **Clasificación:**
 - El sistema almacena un conjunto de categorías.
Cuando se le presenta un patrón de entrada, debe indicar la categoría a la que pertenece.
 - Sistemas de diagnóstico en medicina o en ingeniería

45

- **Extracción de información:**
 - El sistema extrae una información determinada dentro de una gran cantidad de información almacenada
 - Solución a problemas de *data mining*
- **Control:**
 - El sistema imita la capacidad de un cerebro como sistema de cómputo paralelo capaz de manejar miles de actuadores (las fibras musculares) y soportar no-linealidades y ruido
 - Aplicaciones de control industrial y robótica
- **Optimización:**
 - El sistema neuronal se utiliza para resolver problemas de optimización que aparecen en numerosos campos de la ciencia e ingeniería

46

- **Modelado de sistemas y predicción (regresión):**
 - El sistema neuronal “*imita*” la salida que proporciona el sistema modelado frente a unas entradas determinadas
 - En muchos casos es más adecuado trabajar con el modelo que con el sistema real: aplicaciones de medicina, de ingeniería, etc.
 - El modelo puede predecir el comportamiento del sistema real frente a situaciones nuevas: aplicaciones de *marketing*, bursátiles, etc.

8. Bibliografía



Instituto Andaluz
Interuniversitario en
Data Science and
Computational Intelligence



- **Básica:**
 - C. Bishop, “Neural Networks for pattern recognition”, Oxford Press, 1995.
 - Simon Haykin, “Neural Networks”, Prentice Hall, 1999.
 - Presentación de la Universidad de Jaén, EPS. Prof. MJ.Jesus.
- **Complementaria:**
 - Hertz, Krogh and Palmer, “Introduction to the theory of Neural Computation”, Addison-Wesley, 1991.
 - Jang et al. “Neuro-fuzzy and Soft Computing”, Cap. 8-11, Prentice Hall, 1997.
 - C-T Lin y G. Lee, “Neural Fuzzy Systems”, Prentice Hall, 1995.

END